

第一章 绪论

强化学习：智能体 (agent) 在环境 (environment) 中最大化奖励 (reward) 。

一个循环的简要概括：在 t 时刻，智能体观察环境的状态 s_t ，得到观察 (observation) 结果 o_t ，根据决策输出动作 a_t 施加给环境，环境因此产生变化，状态更新为 s_{t+1} ，同时带来奖励 r_{t+1} 。

强化学习与监督学习的区别：没有正确答案；奖励滞后；数据之间有时间顺序；智能体的行为会影响到未来的数据；需要权衡“探索未知动作”和“利用已知动作”。

序列决策

强化学习研究的是**序列决策**，而不是一次性分类。智能体每次动作都会影响之后的状态、可选动作和未来奖励。

几个概念：

- **回合 (episode/trial)**：从开始到结束的完整流程。
- **轨迹 (trajectory)**：记录这一完整流程的一个序列。例如 $\tau = (s_0, a_0, r_0, s_1, a_1, \dots)$ 。
- 与之对比的**历史 (history)**：智能体端到 t 时刻为止记录的流程序列。例如 $H_t = (o_1, a_1, r_1, \dots, o_t, a_t, r_t)$ 。
- **两者区别**：轨迹是全流程，历史是 t 时刻及以前；轨迹中是状态，而历史中是观测。
- **状态与观测**：状态是对世界信息的完整描述，观测可能是状态的一部分，缺失部分信息。

若状态和观测等价，则强化学习可以建模为**马尔科夫决策过程 (MDP)**；反之则为**部分可观测马尔科夫决策过程 (POMDP)**。

MDP 可用一个五元组表示： (S, A, T, R, γ) 。其中， S 为状态空间， A 为动作空间， $T(s' | s, a)$ 为在 s 状态下执行 a 动作、转移为 s' 状态的概率， $R(s, a)$ 为在 s 状态下执行 a 动作得到的奖励， γ 为折扣因子。

POMDP 在 MDP 基础上增加两个和观测相关的量： O 为观测空间， $\Omega(o | s, a)$ 为在 s 状态下执行 a 动作、得到观测结果 o 的概率。

智能体的组成

策略 (policy)：当前状态下采取什么样的动作？一般用字母 π 表示， $\pi(a | s)$ 即为在 s 状态下执行 a 动作的概率。

有两种类型：

- **随机性策略**：根据概率选择动作。例如有两种可能动作， $\pi(a_1 | s) = 0.7$, $\pi(a_2 | s) = 0.3$ ，则有 70% 概率选择 a_1 ，30% 概率选择 a_2 。
- **确定性策略**：直接选取最有可能的动作。在上个例子中，即选择 a_1 。

通常情况下，强化学习一般使用随机性策略。

价值函数 (value function)：对未来奖励的预测，来评估状态的好坏。

有两种类型：

- **策略价值函数 (V 函数)**：在 s 状态下，采用 π 策略，未来能够获得的期望累计奖励。这里所有的下角标 π 都是指“在策略为 π 的前提下”。

$$V_{\pi}(s) := \mathbb{E}_{\pi} [G_t | s_t = s] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s \right], \quad \text{对于所有的 } s \in S$$

- **动作价值函数 (Q 函数)**： s 状态下，先做 a 动作，然后采用 π 策略，未来累计奖励的期望。

$$Q_{\pi}(s, a) := \mathbb{E}_{\pi} [G_t | s_t = s, a_t = a] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right]$$

两者的联系： V 是动作空间对应所有 Q 的加权求和，即

$$V_{\pi}(s) = \sum_a \pi(a | s) Q_{\pi}(s, a)$$

且：现在做 a 后采用 π 策略的价值，就是做 a 的奖励和从下一步开始直接采用 π 策略的价值（当然，需要乘上折扣因子 γ ），即

$$Q_{\pi}(s, a) = \mathbb{E} [R_{t+1} + \gamma V_{\pi}(S_{t+1})]$$

模型与智能体分类

模型 (model)：环境的动态变化规律 + 奖励产生规律。

前者为**转移概率**：在 s 状态下，进行 a 动作，转移到 s' 状态的概率。

$$p_{ss'}^a = p(s_{t+1} = s' | s_t = s, a_t = a)$$

后者为**奖励函数**：在 s 状态下，进行 a 动作，得到的奖励的期望（均值）。

$$R(s, a) = \mathbb{E} [r_{t+1} | s_t = s, a_t = a]$$

强化学习智能体的分类

首先理解一下“学习”的含义：智能体一开始并不知道未来会发生什么，只知道以下四个东西：状态、动作、奖励以及下一状态。学习，就是在不断地从头到尾运行探索后，拟合出上面三种智能体的组成元素：策略、价值函数、模型。

1. 基于价值 / 基于策略

- **基于价值**的智能体 (value-based agent)：学习价值函数 V 和 Q ，然后从中推出策略 π 。
- **基于策略**的智能体 (policy-based agent)：直接学习策略 π 。
- **演员-评论家** (Actor-Critic)：同时学习策略和价值函数，演员负责选择动作，评论家负责评价动作好坏。


2. 有模型 / 免模型

- **有模型** (model-based) 强化学习智能体：简单来说就是学习并建立起环境模型，然后进行预测、模拟、规划。
- **免模型** (model-free) 强化学习智能体：不显式建立环境模型，而是直接从真实交互经验中学习策略或价值函数。

3. 学习与规划

- **学习** (learning)：从真实环境产生的经验获得的信息。
- **规划** (planning)：从环境模型模拟的经验获得信息。

一个流程可紧凑表示为：



左边的路线就是 model-free，右边的路线就是 model-based。

4. 探索与利用

探索与利用：两者矛盾。举例：一直去已知好吃的餐馆，是利用；尝试一家没去过的餐馆（可能比已知最好吃的更好吃，也可能不），是探索。

想要累积奖励最大，则必须在探索与利用之间达成较好的折中。