

第二章 马尔科夫决策过程

马尔科夫过程

马尔科夫性：未来只与现在有关，和过去无关。

$$p(X_{t+1} = x_{t+1} \mid X_{0:t} = x_{0:t}) = p(X_{t+1} = x_{t+1} \mid X_t = x_t)$$

其中， $X_{0:t}$ 表示变量集合 $X_0, X_1, \dots, X_t$ ， $x_{0:t}$ 为在状态空间中的状态序列 $x_0, x_1, \dots, x_t$ 。

可以用**状态转移矩阵** (state transition matrix) 来描述不同状态之间的转移概率：

$$\mathbf{P} = \begin{pmatrix} p(s_1 \mid s_1) & p(s_2 \mid s_1) & \cdots & p(s_N \mid s_1) \\ p(s_1 \mid s_2) & p(s_2 \mid s_2) & \cdots & p(s_N \mid s_2) \\ \vdots & \vdots & \ddots & \vdots \\ p(s_1 \mid s_N) & p(s_2 \mid s_N) & \cdots & p(s_N \mid s_N) \end{pmatrix}$$

其中， $p(s_i \mid s_j)$ 表示在 s_j 状态下一步转移到 s_i 状态的概率。

马尔科夫奖励过程

在马尔科夫过程中增加了**奖励函数** R 和**折扣因子** γ 。最基础的奖励，就是 Markov 链中从一个状态转移到另一状态时得到的一个数（这个数有时也是随机变量）。

从 t 时刻到 $t+1$ 时刻状态转移带来的奖励记为 r_{t+1} 。从 t 时刻开始，某一条 Markov 链所得到的**奖励加权和（折扣回报）**为：

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots$$

状态价值函数：当前 s 状态下，能够发生的所有 Markov 链的折扣回报之期望，即

$$V(s) = \mathbb{E}[G_t \mid s_t = s]$$

与之对应的**奖励函数**有很多变体：

- $R(s)$ ：当前 s 状态下，通过**一步转移**得到的奖励的期望。
- $R(s, a)$ ： s 状态采取 a 行动、一步转移得到的奖励的期望。
- $R(s, a, s')$ ： s 状态采取 a 行动、转移到 s' 状态的奖励的期望。

如何求解某一状态的价值 $V(s)$ ？**贝尔曼方程**：

$$V(s) = \underbrace{R(s)}_{\text{即时奖励}} + \gamma \underbrace{\sum_{s' \in S} p(s' | s) V(s')}_{\text{未来奖励的折扣总和}}$$

直观理解：当前状态 s 的价值，等同于从这个状态所有情况一步转移得到的价值，再加上打过一次折扣的下一步状态的价值。

我们可以把贝尔曼方程写成矩阵的形式：

$$\begin{pmatrix} V(s_1) \\ V(s_2) \\ \vdots \\ V(s_N) \end{pmatrix} = \begin{pmatrix} R(s_1) \\ R(s_2) \\ \vdots \\ R(s_N) \end{pmatrix} + \gamma \begin{pmatrix} p(s_1 | s_1) & p(s_2 | s_1) & \cdots & p(s_N | s_1) \\ p(s_1 | s_2) & p(s_2 | s_2) & \cdots & p(s_N | s_2) \\ \vdots & \vdots & \ddots & \vdots \\ p(s_1 | s_N) & p(s_2 | s_N) & \cdots & p(s_N | s_N) \end{pmatrix} \begin{pmatrix} V(s_1) \\ V(s_2) \\ \vdots \\ V(s_N) \end{pmatrix}$$


从中可以直接得到**解析解 (analytic solution)**：

$$V = (I - \gamma \mathbf{P})^{-1} R$$

蒙特卡洛方法与自举

但是这样计算量太大，于是我们有近似估算方法：**蒙特卡洛方法 (采样取均值)**。要计算某状态的价值，就从某状态开始跑多次马尔科夫过程，每次记录轨迹得到多条 Markov 链，根据其计算 G_t ，对 G_t 求期望即 V 的估计值。

还有一种方法：**自举**。下图是一个马尔科夫链的状态转移图。



【图片：图中有四个状态节点 s_1, s_2, s_3, s_4 ；可见转移概率包括 $s_1 \rightarrow s_1$ 的 0.1、 $s_1 \rightarrow s_2$ 的 0.2、 $s_1 \rightarrow s_4$ 的 0.7、 $s_4 \rightarrow s_4$ 的 0.5、 $s_4 \rightarrow s_3$ 的 0.2、 $s_4 \rightarrow s_2$ 的 0.3、 $s_3 \rightarrow s_2$ 的 1，以及 $s_2 \rightarrow s_1$ 的 1。】

箭头上标注的是转移概率，但这里我们可以再加上一条：转移得到的奖励值。比如 s_1 转移到 s_2 能得到 10 的奖励，就有方程： $V(s_1) = 10 + \gamma V(s_2)$ 。

诸如此类，将整个图转换为一个方程组，我们的目标就是解出这个方程组。而这个方程组正是上面的**矩阵形式的贝尔曼方程组**。

也就是说，自举法**还是在解方程**，解的还是贝尔曼方程组，只不过方法不一样：**先给每个状态的价值都赋值为 0，然后重复迭代更新这些值，直到这些值基本上不再变化（收敛）。**

更简单地说，就是对方程

$$V = R + \gamma \mathbf{P}V$$

将右侧的 V 进行全赋值为 0，然后计算左侧 V ；再将计算出来的左侧 V 带入右侧进行下一轮计算.....直到收敛。

马尔科夫决策过程

在前面的基础上增加了动作这一因素，区别如下图所示。




图 2.9 马尔可夫决策过程与马尔可夫过程/马尔可夫奖励过程的状态转移的对比

图 2.9：马尔科夫决策过程与马尔科夫过程/马尔科夫奖励过程的状态转移对比。左侧展示状态直接转移到下一状态；右侧展示状态先按策略选择动作，再由状态和动作共同决定下一状态。

动作价值函数 Q ：在 π 策略、 s 状态下，采取 a 动作得到的回报的期望（后续全过程而不是单步）。

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

于是有（和前面是一样的，只不过加上了表示策略的角标）：

$$V_{\pi}(s) = \sum_{a \in A} \pi(a \mid s) Q_{\pi}(s, a)$$

同理，可以得到**贝尔曼期望方程（递推关系）**：

$$V_{\pi}(s) = \mathbb{E}_{\pi}[r_{t+1} + \gamma V_{\pi}(s_{t+1}) \mid s_t = s]$$

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[r_{t+1} + \gamma Q_{\pi}(s_{t+1}, a_{t+1}) \mid s_t = s, a_t = a]$$

展开写也就是：

$$V_{\pi}(s) = \sum_{a \in A} \pi(a \mid s) \left(R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) V_{\pi}(s') \right)$$

$$Q_{\pi}(s, a) = R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) \sum_{a' \in A} \pi(a' \mid s') Q_{\pi}(s', a')$$

道理是一样的，就不多赘述了。

策略评估 / 预测

策略评估/预测：给定策略，计算 $V_{\pi}(s)$ 。

方法：给 $V_{\pi}(s)$ 一个初值，代入方程右侧中的 $V_{\pi}(s')$ ，计算得到左侧的 $V_{\pi}(s)$ ，再代回右侧循环往复，直到数值不再更新：

$$V_{\pi}(s) = \sum_{a \in A} \pi(a \mid s) \left(R(s, a) + \gamma \sum_{s' \in S} p(s' \mid s, a) V_{\pi}(s') \right)$$

控制

控制：现在没有策略，需要**找到最优策略**，以及其对应的最优期望奖励。

方法：先生成一个随机策略 π_0 ，然后算一张表： Q_{π_0} （所有状态、所有动作）。根据这张表，提出一个新的策略 π_1 ：对于每一状态 s_i ，都直接采取使 $Q_{\pi_0}(s_i, a_j)$ 取最大值的 a_j 。然后重新迭代：算 Q_{π_1} （所有状态、所有动作）.....

直到 π_k 和 π_{k+1} 完全相同（收敛），则此时达到了最佳策略 π^* 。

计算 $Q_{\pi}(s, a_i)$ 的方法：先用预测算 $V_{\pi}(s)$ ，然后计算得到 $Q_{\pi}(s, a_i)$ 。

利用公式：

$$Q_{\pi}(s, a) = R(s, a) + \gamma \sum_{s'} P(s' \mid s, a) V_{\pi}(s')$$

$$V_{\pi}(s) = \sum_a \pi(a \mid s) Q_{\pi}(s, a)$$