

第十一章 模仿学习

当环境没有明确的奖励函数，但是有**专家的操作示范**，如何训练？

行为克隆 (BC)

这个最好理解：你啥都不会，看到会的人给你做示范，**照猫画虎**就好。

用更严谨的符号语言来表达，就是：专家在环境中产生了许多状态—动作对：

$$\mathcal{D}_E = \{(s_1^E, a_1^E), (s_2^E, a_2^E), \dots, (s_N^E, a_N^E)\}$$

其中， s_i^E 表示专家当时看到的状态或观测； a_i^E 表示专家在该状态下采取的动作； π_θ 表示待训练的策略网络； θ 表示策略网络参数。

行为克隆希望训练出一个策略，使 $\pi_\theta(s_i^E) \approx a_i^E$ 。也就是说，它不直接学习“怎样获得高奖励”，而是**直接学习“专家在这里做了什么”**。

然后这就转变为了监督学习，类似于图形分类里面区分猫狗一样。

但是有问题：专家的示范都是成功的，**没有“出现偏差或者失误后该如何补救”**。

一旦智能体**偏离专家示范的状态**（而这几乎是必然的。例如即使每个动作都有高达 99% 的概率做对，100 次连续动作全对的概率仅剩 36.6%），就**变成“无头苍蝇”**，只能通过神经网络的泛化来决定动作，这显然是不好的。总结起来就是：策略出现小误差 → 进入专家数据之外的状态 → 网络缺少正确标签 → 继续犯错。

我们提出一种新的方法：**数据集聚合 (DAgger)**。

普通行为克隆是：专家运行 → 收集专家状态和动作 → 训练策略。

DAgger 则是：专家数据训练初始策略 → **学习策略自己运行** → **专家给学习者遇到的状态提供正确动作** → 合并数据 → 重新训练。

这样相当于**扩大了样本的覆盖范围，让智能体学习处理偏离了一开始专家状态的情况**。代价是专家需要一直参与训练，可能比较昂贵。

逆强化学习 (IRL)

行为克隆比较方便理解，但是容易造成“知其然而不知其所以然”。

逆强化学习就是尝试从“知其然”到“知其所以然”。

简单来说，就是：**专家策略** → **奖励函数** → **最优策略**。

具体细节：首先我们有若干条专家做的示范轨迹，组成一个集合：

$$\mathcal{D}_E = \{\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_N\}$$

然后初始化一个什么也不会的演员，他的策略为 π_{θ_0} 。让他自己跑得到若干条轨迹组成集合：

$$\mathcal{D}_{\theta_0} = \{\tau_1, \tau_2, \dots, \tau_N\}$$

然后，训练**奖励模型** R_ϕ ，输入轨迹输出奖励。显然，专家轨迹的奖励高，新手轨迹的奖励低是合理的，即 $R_\phi(\hat{\tau}) > R_\phi(\tau)$ 。

训练好一个暂时的 R_ϕ 以后，将其冻结，就认为它是环境奖励：

$$r_t = r_\phi(s_t, a_t)$$

此时已经有了环境的奖励，就可以按照之前的普通强化学习方法来训练策略 π_θ 。

策略学习一段时间稍微变好后，用当前策略再去跑若干条轨迹，然后用这些轨迹与专家轨迹返回去训练奖励模型 R_ϕ ，然后循环往复这个过程。

也就是说，这是一个交替优化过程：

$$\phi \longrightarrow \theta \longrightarrow \phi \longrightarrow \theta \longrightarrow \dots$$

其中，更新 ϕ ：让奖励模型更会区分专家和演员；更新 θ ：让演员更会获得奖励模型给出的高分。

这有点像对抗：奖励模型希望区分专家和演员；演员希望让自己的轨迹获得和专家一样的高分。即：

$$\begin{array}{ll} \text{奖励模型:} & \hat{\tau} \text{ 高分, } \tau_\theta \text{ 低分,} \\ & \tau_\theta \text{ 高分} \end{array}$$

所以演员会不断尝试“骗过”奖励模型，而奖励模型则不断寻找演员行为中的漏洞。

第三人称视角模仿学习

当专家和智能体观察的角度不同时，如何处理这个偏差？

例如，拍摄的人类（专家）打高尔夫球的数据是以第三人称而呈现的，但智能体打高尔夫球时只能看到眼前的画面（第一人称），两者会出现偏差。称之为**领域差异**。

符号化表述： $o^{(3)}$ 和 $o^{(1)}$ 不同，前者是第三人称的观察，后者是第一人称的观察。

如何解决？**找任务特征，用同一套策略处理任务特征来得到输出**，即：

$$\begin{aligned}o^{(3)} &\xrightarrow{f_\psi} z^{(3)} \xrightarrow{\pi_\theta} a, \\ o^{(1)} &\xrightarrow{f_\psi} z^{(1)} \xrightarrow{\pi_\theta} a.\end{aligned}$$

其中 f_ψ 是我们要训练的**特征提取器**（是一个神经网络）（有点像第十章的好奇心里面，处理状态得到与任务相关的特征）， $z^{(3)}$ 、 $z^{(1)}$ 是提取出的任务特征。

我们自然希望 $z^{(3)} \approx z^{(1)}$ ，这也是特征提取器的任务之一。

但是，**特征提取器并不知道自己提取的东西是不是真的“特征”**，还是混入了一些无关因素，所以这里再引入一个新的网络：**领域分类器** D_ω 。

它的任务是：输入任务特征 z ，判断其是由第一人称观察转换来的还是第三人称，也就是说，尽可能准确地判断任务特征来自的领域。

简单理解：只要领域分类器还能比较准确地判断，就说明特征提取器提取的东西里面不只有特征，还包含了与领域有关的、我们希望去掉的因素。

总结：两个网络，两个对抗的目标：

- **特征提取器**：让任务预测正确，同时让领域分类器无法判断领域。
- **领域分类器**：根据特征 z ，尽可能准确地判断它来自哪个领域。

训练时，两者交替更新。这称之为**领域对抗训练**。

番外篇：对抗

本章的逆强化学习和领域对抗训练都应用了**对抗**的思想。

简单来说，对抗就是一方主动寻找另一方的缺陷，另一方根据这些缺陷改进自己；双方交替增强，直到其中一方难以再区分或击败另一方。

直观理解：“魔高一尺道高一丈”，如果奖励固定，则容易被钻空子。对抗有利于发现并修补“空子”，但由于目标一直变化，训练会更加复杂，稳定性也会下降。

举个例子：**生成对抗网络（GAN）**。

生成器 G （网络参数 θ ）：由随机噪声 z 生成假样本 x_{fake} 。

判别器 D （网络参数 ϕ ）：接收一个样本，输出其为真实样本的概率。

训练流程如下：

1. 采样真实样本并打标签；由 G 生成一批假样本并打标签。
2. **依次更新：先冻结 G** ，将样本喂给判别器 D 做监督学习，**更新 D 的参数。**
3. **冻结 D ，解冻 G** ， G 生成一堆样本输入 D ，根据反向传播的梯度**更新 G** ，目标是让 D 尽可能对 G 生成的假样本输出 1（欺骗判别器）。循环往复。

最终理想情况下迭代到： G 生成的样本和真实样本的分布一致，无法区分， D 无法判断，输出 $1/2$ 。

直观理解：

生成器：伪造者；判别器：鉴定专家；真实数据：真品；生成数据：赝品。

训练过程就是：伪造者先粗略造假 → 鉴定专家找出破绽 → 伪造者根据破绽改进 → 鉴定专家继续提高鉴别能力 →

最终希望达到：鉴定专家即使认真检查，也无法可靠区分真品和赝品。